

“Predicción trimestral de la tasa de natalidad en el Perú: Una comparación de modelos de Machine Learning a nivel departamental”

Autores: John Arzapalo, Ariana Burga, Ricardo Lara, Luis Miranda, Alessandro Santé y Juan Zavala.

Resumen – La tasa de natalidad es un indicador clave de la transición demográfica. Durante el último siglo, ha mostrado una tendencia a la baja global, replicada en Perú. Esta reducción requiere análisis para la toma de decisiones en salud, educación y pensiones. Se evaluaron modelos de machine learning (Regresión Lineal, KNN, Árboles de Regresión, Random Forest y XGBoost) para predecir la tasa de natalidad trimestral departamental. Con datos del Registro de Nacidos Vivos (2015-2025), XGBoost mostró el mejor desempeño ($R^2 = 0.91$), identificando variables temporales (53.04%) y geográficas (37.5%) como factores más influyentes, destacando Huancavelica y Madre de Dios por su alta variabilidad. La exclusión del período COVID-19 mejoró significativamente la precisión.

1. Introducción

La transición demográfica en el Perú se manifiesta en cambios significativos en los patrones de natalidad. A nivel global, este indicador ha mostrado un declive consistente durante el último siglo (The Economist 2023), tendencia que se replica en el contexto peruano con particularidades regionales que demandan un análisis específico a nivel departamental. Esta reducción genera desafíos de envejecimiento poblacional, donde una base joven reducida debe sustentar económicamente a un creciente número de adultos mayores.

La comprensión de la evolución de la tasa de natalidad resulta fundamental para el diseño de políticas públicas descentralizadas en salud, educación y pensiones (Castellares, Camacho y Huarancca 2024: 65). Sin embargo, los métodos tradicionales de proyección demográfica no capturan la complejidad de las relaciones sociodemográficas subnacionales.

Frente a estas limitaciones, este estudio propone la implementación comparativa de modelos de machine learning para la predicción trimestral a nivel departamental: Regresión Lineal, K-Nearest Neighbors (KNN), Árboles de Regresión, Random Forest y XGBoost. La hipótesis central plantea que al menos un modelo alcanzará un desempeño predictivo satisfactorio, definido por un R^2 superior a 0.7 y un MAE inferior a 0.5 puntos.

La pregunta de investigación que guía este trabajo se centra en determinar:

- ¿Qué modelo de machine learning provee el mejor desempeño predictivo de la tasa de natalidad trimestral a nivel departamental

en el Perú, y cuáles son las variables con mayor influencia predictiva?

Para responder esta interrogante, el objetivo general consiste en:

- Desarrollar y comparar un sistema predictivo de la tasa de natalidad trimestral utilizando modelos de machine learning con datos del Registro de Nacidos Vivos (2015-2025) para el ámbito departamental.

Los objetivos específicos incluyen:

- Procesar y transformar los datos con técnicas de preprocesamiento, ingeniería de características y agregación trimestral departamental.
- Implementar y entrenar los modelos considerando la naturaleza temporal.
- Evaluar y comparar el desempeño predictivo utilizando métricas estandarizadas (MSE, MAE, R^2) con validación temporal.
- Identificar y analizar las variables con mayor influencia predictiva en el mejor modelo.

2. Trabajos relacionados

Predicting Future Birth Rates with the Use of an Adaptive Machine Learning Algorithm: A Forecasting Experiment for Scotland

La investigación compara modelos de regresión, entre ellos Regresión Lineal y árboles de decisión, para pronosticar nacimientos mensuales en Escocia. Los resultados evidencian que los métodos basados en árboles superan a los lineales, demostrando su mayor capacidad para representar relaciones no lineales en las tasas de natalidad. (Tziritidou-Chatzopoulou, Zournatzidou y Kourakos 2024: 4–5; 7–9). Este hallazgo fundamenta nuestra inclusión de

algoritmos basados en árboles y justifica la comparación con métodos lineales como referencia.

Análisis de reducción de tasas de natalidad en Colombia: un enfoque con técnicas de aprendizaje automático

El estudio utiliza datos del DANE (2019–2022) para predecir la natalidad mediante Árbol de Decisión, Random Forest y XGBoost. Se resalta que el Árbol de Decisión identifica factores determinantes como la educación materna y el año, confirmando su utilidad para explicar patrones demográficos y contrastarlo con enfoques lineales tradicionales. (Largo y Valencia, 2024: 13–17). La efectividad de XGBoost reportada en contextos latinoamericanos similares valida su selección como candidato principal en nuestro estudio.

Predicción de factores clave en el aumento de la demografía en Colombia a través del ensamble de modelos de Machine Learning

Este trabajo aplica Regresión Lineal, KNN y Árboles de Decisión para analizar la natalidad en Colombia, integrándolos en un modelo de ensamble tipo Bagging. Los hallazgos revelan que el Árbol de Decisión alcanza el mejor rendimiento, validando su eficacia frente a métodos lineales para describir la relación entre variables sociodemográficas y nacimientos (Ordóñez-Erazo, Ordóñez y Bucheli-Guerrero 2022: 285). Este enfoque comparativo inspira nuestra metodología de evaluación múltiple de algoritmos.

Estos tres estudios brindan un marco comparativo fundamental para nuestra investigación, al demostrar la aplicabilidad de modelos como Regresión Lineal, KNN, Árboles de Decisión, Random Forest y XGBoost en la predicción de tasas de natalidad y el análisis de factores sociodemográficos. Sin embargo, identificamos una brecha metodológica: ninguno aborda la predicción trimestral con agregación espacio-temporal ni aprovecha variables de series de tiempo (lags, medias móviles) en el contexto departamental. Nuestro estudio expande este marco al contexto peruano, incorporando la totalidad de estos modelos y orientándolos a una predicción trimestral departamental que capture tanto la variabilidad temporal como las heterogeneidades regionales específicas del Perú.

3. Metodología

3.1 Enfoque propuesto

Este estudio busca predecir la tasa de natalidad trimestral departamental en Perú mediante algoritmos de machine learning. Formalmente, sea **X** el conjunto de variables demográficas, temporales y geográficas, y **Y** la tasa de natalidad

en un trimestre determinado para un departamento específico. El problema consiste en encontrar una función **f: X → Y** que aproxime de manera óptima la relación entre las variables de entrada y la natalidad trimestral. Para ello, se evaluarán cinco algoritmos de machine learning aplicados en problemas de predicción.

3.2 Recopilación de los Datasets

A través de la Plataforma Nacional de Datos Abiertos del Perú y el Geodir, se obtuvieron dos datasets para este estudio:

- **Registros de Nacidos Vivos en el Perú (2015–2025):**

Dataset oficial que contiene registros individuales de nacimientos con variables cualitativas y cuantitativas clasificadas por demografía, salud y geografía. Incluye el Código de Ubicación Geográfica (Ubigeo) que permite vincular cada nacimiento con su ubicación específica a nivel de distrito, provincia y departamento.

Tabla 1

Variables del Dataset de Registros de Nacidos Vivos

#	Variable	#	Variable
1	Año del nacimiento	12	Número de embarazos anteriores
2	Mes del nacimiento	13	Número de hijos vivos
3	Peso al nacer	14	Número de hijos fallecidos
4	Tamaño al nacer	15	Número de abortos o nonatos
5	Duración gestacional	16	País de origen de la madre
6	Condición del parto	17	Código de ubicación geográfica (Ubigeo)
7	Sexo del recién nacido	18	Ocupación de la madre
8	Modalidad del parto	19	Código del establecimiento de salud certificador
9	Edad de la madre	20	Lugar de nacimiento
10	Estado civil de la madre	21	Tipo de atención en el parto
11	Nivel educativo de la madre	22	Fuente de financiamiento del parto

Nota. Tomado de Plataforma Nacional de Datos Abiertos:

<https://www.datosabiertos.gob.pe/dataset/registros-de-nacidos-vivos-en-el-per%C3%BA-2015%E2%80%932025>

- **Catálogo de Ubigeo del INEI (2019):** Listado oficial del Instituto Nacional de Estadística e Informática que detalla cada unidad

geográfica del país (ubigeo, departamento, provincia y distrito), así como variables demográficas y geográficas asociadas. Este catálogo sirve como clave de vinculación para la georreferenciación de los nacimientos.

Tabla 2

Variables del Dataset Ubigeo de Perú (INEI)

#	Variable	#	Variable
1	Código de ubicación geográfica (Ubigeo)	5	Población
2	Distrito	6	Superficie
3	Provincia	7	Y
4	Departamento	8	X

Nota. Tomado de Ubigeo de Perú (INEI): <https://account.geodir.co/recursos/ubigeo-inei-peru.html>

Los cinco modelos implementados (Regresión Lineal, KNN, Árboles de Regresión, Random Forest y XGBoost) comparten la misma estructura de entrada/salida, diseñada para capturar patrones espacio-temporales de natalidad.

3.3 Entrada y Salida

Entrada (X): Variables procesadas y agregadas a nivel trimestral-departamental:

- **Temporales:** Año y trimestre; variables de lag (lag1, lag4); media móvil de 4 trimestres (ma4).
- **Sociodemográficas:** Edad materna (media, porcentaje de adolescentes, porcentaje de mayores de 35 años); historia reproductiva (promedio de embarazos, hijos vivos y abortos); características socioculturales (proporciones de estado civil, nivel educativo, lugar de nacimiento y financiador del parto).
- **Geográficas:** Departamento (codificado como variables dummy mediante one-hot encoding); población departamental.

Salida (Y): Tasa de natalidad trimestral por departamento, calculada como:

$$Y = \frac{\text{Nacimientos en departamento } D \text{ durante trimestre } T}{\text{Población del departamento } D} \times 1000$$

Este enfoque integra las dimensiones temporal, geográfica y sociodemográfica del fenómeno.

3.4 Preprocesamiento y estructuración de Datos

El proceso transformó registros individuales de nacimientos en un panel de series temporales mediante:

- **Limpieza y Validación de Datos:** Se eliminaron 953 registros duplicados y se trataron valores inválidos, reemplazando "IGNORADO" por NaN en variables categóricas. Se normalizaron variables numéricas especiales (ej: ">=5" → 5, "-1" → NaN) y se eliminó la columna Hijos_Fallecidos_Madre por alto porcentaje de valores nulos (96.96%).
- **Selección y Transformación de Características:** Se eliminaron 10 variables no relevantes para la predicción (características del bebé, detalles del parto) y se agruparon categorías en estado civil, nivel educativo, lugar de nacimiento y financiador del parto.
- **Integración Geográfica y Temporal:** Se utilizó el código Ubigeo para vincular cada nacimiento con el catálogo geográfico del INEI, enriqueciendo los registros con el nombre del departamento. Se creó la variable trimestre a partir del mes de nacimiento y se eliminaron los registros sin departamento asignado.
- **Cálculo de Poblaciones Trimestrales:** A partir de datos poblacionales anuales del INEI, se generaron estimaciones trimestrales mediante interpolación lineal, considerando tasas de crecimiento histórico por departamento. Este proceso permitió obtener los denominadores poblacionales necesarios para el cálculo preciso de tasas de natalidad trimestrales.
- **Agregación Espacio-Temporal:** Los datos se agruparon por año, departamento y trimestre. Para cada grupo, se contabilizó el número total de nacimientos, se calcularon estadísticas de edad materna (media, % adolescentes, % >35 años), promedios de variables reproductivas (embarazos, hijos vivos, abortos) y proporciones de variables categóricas agrupadas.
- **Ingeniería de Características Temporales:** Se crearon variables de series de tiempo: tasa de natalidad del trimestre anterior (Lag1), tasa del mismo trimestre del año anterior (Lag4) y media móvil de 4 trimestres (MA4).
- **División Temporal de Datos:** Considerando la naturaleza secuencial y el impacto COVID, los datos se dividieron en: entrenamiento (hasta 2022), validación (2023) y prueba (2024 - 2025, excluyendo 2025-T3). Se excluyó el período COVID (2020 - 2021-T2) para mejorar la robustez predictiva.

Figura 1*División Temporal de los Datos*


Nota. Elaboración propia basada en el procesamiento del Registro de Nacidos Vivos. Se excluyó el periodo COVID (2020 - 2021-T2).

- **Variable Objetivo:** La tasa de natalidad trimestral se calculó para cada grupo utilizando:

$$Tasa = \frac{Nacimientos}{Población} \times 1000$$

utilizando las poblaciones trimestrales estimadas como denominador.

El dataset final para modelado integró variables de entrada organizadas en categorías temporales (año, trimestre, lags, medias móviles), sociodemográficas (edad, educación, estado civil), geográficas (departamento codificado) y de salud reproductiva (embarazos, hijos vivos, abortos).

Figura 2*Pipeline de Procesamiento de Datos*

Nota. Elaboración propia.

3.5 Modelos y Entrenamiento

Se implementaron cinco modelos predictivos representando distintos enfoques algorítmicos para capturar patrones espacio-temporales en datos demográficos:

- **Regresión Lineal:** Se utilizó como modelo baseline por su simplicidad y transparencia interpretativa. Permite establecer relaciones lineales entre las variables predictoras y la

tasa de natalidad, sirviendo como referencia para modelos más complejos.

- **K-Nearest Neighbors (KNN):** Se implementó con $k=5$ y $k=10$ para capturar patrones de similitud temporal y espacial, utilizando distancia Euclidiana. Este modelo estima la tasa esperada basándose en los trimestres y departamentos más similares históricamente, aprovechando la estructura de panel de los datos.
- **Árbol de Regresión:** Se configuró con máxima profundidad de 6 para identificar umbrales críticos y relaciones no lineales. Su capacidad de interpretación permite detectar cambios estructurales específicos por departamento y capturar interacciones entre variables temporales y geográficas.
- **Random Forest:** Ensemble de 100 árboles con máxima profundidad 6, que combina múltiples árboles de decisión para reducir sobreajuste y mejorar la generalización para departamentos con menor cantidad de datos históricos.
- **XGBoost:** Modelo de boosting gradient con 200 estimadores, learning rate de 0.05 y máxima profundidad de 6. Optimizado para capturar relaciones complejas mediante el aprendizaje secuencial de árboles, particularmente efectivo para las dependencias temporales (lags) y la heterogeneidad departamental.

La comparación sistemática evalúa paradigmas de predicción lineal, por similitud y basados en árboles para determinar el mejor ajuste a la naturaleza espacio-temporal de los datos demográficos departamentales.

3.6 Configuración Experimental

El diseño experimental se estructuró para garantizar una evaluación robusta y reproducible de los modelos predictivos, considerando la naturaleza temporal de los datos y las particularidades del contexto demográfico peruano.

- **Validación Temporal:** Se implementó validación cruzada temporal (TimeSeriesSplit) con 5 folds, respetando estrictamente el orden cronológico de los datos para evaluar el desempeño predictivo en secuencias temporales futuras. Los folds se construyeron de manera que cada conjunto de validación contenía períodos posteriores al conjunto de entrenamiento, simulando el escenario real de predicción futura.
- **Métricas de Evaluación:** Se seleccionaron tres métricas estandarizadas para evaluación comparativa:
 - **R² (Coeficiente de Determinación):** Mide la proporción de varianza

explicada por el modelo en la escala 0-1.

- **RMSE (Root Mean Square Error):** Cuantifica el error cuadrático promedio en la escala original de la tasa de natalidad (puntos por 1000 habitantes).
- **MAE (Mean Absolute Error):** Representa el error absoluto promedio, menos sensible a valores atípicos.
- **Pipeline de Procesamiento:** Se configuró un flujo unificado mediante ColumnTransformer que incluye:
 - Escalado de variables numéricas continuas mediante StandardScaler
 - Codificación one-hot para la variable categórica Departamento.
 - Preservación de variables temporales básicas (año, trimestre) sin escalar para mantener su interpretabilidad temporal.
- **Estrategia Experimental:** Se diseñaron cuatro experimentos principales:
 1. **Comparación base:** Evaluación de los 5 algoritmos mediante validación cruzada temporal (TimeSeriesSplit) con configuración estándar.
 2. **Entrenamiento final:** Entrenamiento de modelos con conjunto completo (train + validation) para evaluación en test.
 3. **Evaluación temporal:** Prueba en datos recientes (2024 - 2025) para simular desempeño en producción.
 4. **Robustez COVID:** Comparativa excluyendo el período atípico (2020 - 2021-T2) para validar generalización.

3.7. Análisis de Importancia de Variables

Se implementó un análisis de importancia de variables en XGBoost (modelo de mejor desempeño) para interpretar factores predictivos clave:

- **Importancia por Ganancia (Gain):** Se utilizó la métrica nativa de XGBoost que mide la mejora promedio en la precisión de las predicciones aportada por cada variable al construir los árboles.
- **Agrupación por Categorías:** Las variables se clasificaron en categorías temáticas para un análisis interpretativo:
 - **Temporal:** lag1, lag4, ma4, año, trimestre
 - **Geográfico:** variables dummy de departamento
 - **Edad Materna:** edad media, % adolescentes, % >35 años
 - **Sociodemográfico:** educación, estado civil, características de atención
 - **Salud Reproductiva:** embarazos, hijos vivos, abortos
- **Análisis de Patrones Departamentales:** Se examinó específicamente la importancia de

las variables geográficas para identificar departamentos con mayor influencia predictiva y analizar sus características demográficas distintivas.

Este análisis valida la consistencia del modelo con el conocimiento del dominio e identifica patrones críticos para políticas públicas descentralizadas.

4. Experimentación y Resultados

4.1. Setup Experimental

El diseño experimental evaluó rigurosamente el desempeño predictivo en series temporales departamentales:

- **Datos Utilizados:**

Se procesaron 4769428 registros individuales de nacimientos (2015 - 2025), obtenidos del Registro de Nacidos Vivos del Perú.

Figura 3
Dataset inicial

	Año_Nacimiento	Mes_Nacimiento	Peso_Nacido	Talla_Nacido	Duracion_Embarazo
0	2021	1	3425	51.4	41
1	2021	1	3320	48.0	40
2	2021	1	3200	50.0	39
3	2020	10	3850	51.0	39
4	2021	1	3990	51.0	38

Nota. Se muestran 5 columnas de las 22 y 5 filas de las 4769428.

Para el cálculo de tasas, se generaron poblaciones trimestrales mediante interpolación lineal a partir de datos anuales del INEI.

Figura 4
Poblaciones Trimestrales

	Año	Trimestre	Departamento	Poblacion_Trimestral	Tasa_Crecimiento_Trimestral_%	Periodo
24	2015	T1	Amazonas	408751	0.082759	2015-T1
25	2015	T2	Amazonas	409444	0.169541	2015-T2
26	2015	T3	Amazonas	410138	0.169498	2015-T3
27	2015	T4	Amazonas	410832	0.169211	2015-T4
28	2016	T1	Amazonas	411525	0.168682	2016-T1

Nota. Cada departamento, tiene su población y tasa de crecimiento para cada trimestre.

Después del preprocesamiento, agregación espacial e ingeniería de características temporales, se obtuvo un dataset panel a nivel trimestral-departamental con 25 departamentos y 28 variables predictoras, incluyendo features temporales (lag1, lag4, ma4), sociodemográficas agregadas y geográficas.

Figura 5
Dataset final

	Departamento	Año	Trimestre	Edad_Media	Pct_Adolescentes
0	AMAZONAS	2015	1	27.203866	0.144112
1	AMAZONAS	2015	2	26.524510	0.194444
2	AMAZONAS	2015	3	26.683564	0.176651
3	AMAZONAS	2015	4	26.439311	0.198904
4	AMAZONAS	2016	1	26.895273	0.172364

Nota. Se muestran 5 columnas de las 23 y 5 filas de las 1075 observaciones del panel trimestral-departamental.

Para el experimento principal, se excluyó el período COVID-19 (2020 - 2021-T2) para evitar sesgos por eventos atípicos y el conjunto de prueba cubre el período 2024 - 2025 (excluyendo 2025-T3 por datos incompletos).

- **Estrategia de Evaluación:**
Se empleó validación cruzada temporal (TimeSeriesSplit) con 5 folds, respetando el orden cronológico, complementada con un conjunto de prueba independiente. Las métricas seleccionadas fueron R^2 , RMSE y MAE, estandarizadas para evaluación comparativa.
- **Experimentos:**
 1. Comparación de cinco algoritmos mediante TimeSeriesSplit.
 2. Entrenamiento final y evaluación en prueba.
 3. Análisis de robustez excluyendo COVID-19
 4. Análisis de importancia de variables en el mejor modelo.

4.2 Resultados y Discusión

Los resultados de la validación cruzada temporal (Tabla 3) revelaron que XGBoost obtuvo el mejor desempeño global ($R^2=0.8632$, $MAE=0.1955$), seguido por Random Forest ($R^2=0.8493$).

Tabla 3
Resultados de Validación Cruzada Temporal

Modelo	R^2 promedio	RMSE promedio	MAE promedio
Regresión Lineal	0.7309	0.3527	0.2737
KNN (k=5)	0.7027	0.3636	0.2892
KNN (k=10)	0.6544	0.4075	0.3280
Árbol de Regresión	0.7118	0.3606	0.2715
Random Forest	0.8493	0.2747	0.2107
XGBoost	0.8632	0.2593	0.1955

Nota. Promedio de métricas en validación cruzada temporal.

Los modelos basados en árboles superaron consistentemente a los lineales y basados en similitud (KNN), lo que sugiere que las relaciones no lineales y las interacciones entre variables son cruciales para predecir la natalidad. La Regresión Lineal, aunque menos precisa, cumplió con el

umbral de $R^2 > 0.7$ establecido en la hipótesis, sirviendo como baseline adecuado. Al ser el mejor modelo, XGBoost fue reentrenado con el conjunto completo de entrenamiento y validación (2015 - 2023) y evaluado en el período de prueba 2024 - 2025.


Tabla 4
Resultados de Validación Cruzada Temporal

Modelo	R^2 score	RMSE en test	MAE en test
XGBoost	0.9107	0.2144	0.1618

Nota. Evaluación en datos 2024 - 2025.


El modelo demostró capacidad de generalización con R^2 de 0.9107 (superior al umbral de 0.7) y MAE de 0.1618 (inferior a 0.5), validando la hipótesis. La mejora consistente de R^2 entre validación (0.8632) y prueba (0.9107) confirma la ausencia de sobreajuste y adecuada generalización a datos futuros.

Figura 6
Gráfico de líneas comparativo



Nota. Las predicciones (naranja) siguen consistentemente la tendencia real (azul)..

Figura 7
Gráfica de dispersión



Nota. Puntos cercanos a la línea $y=x$ indican alta precisión predictiva.

Para evaluar la robustez del modelo, se comparó el desempeño de XGBoost entrenado con y sin el período COVID-19.

Tabla 5

Impacto del Período COVID-19 en XGBoost

Condición	R^2	RMSE	MAE
Sin COVID	0.9107	0.2144	0.1618
Con COVID	0.8887	0.2394	0.1840


Nota. Comparación con y sin datos 2020 - 2021-T2.

Los resultados de la Tabla 5 evidencian que la exclusión del período COVID-19 mejoró todas las métricas. Este resultado respalda la decisión de excluir el período pandémico, ya que los eventos atípicos introducen ruido que dificulta la generalización del modelo y la identificación de patrones estructurales.

Finalmente, se analizó la importancia de las variables en el modelo XGBoost de forma independiente. Se identificaron las siguientes:

Figura 8

Top 15 Variables Más Influyentes en XGBoost



Nota. Variables temporales (lag1, ma4) y geográficas dominan la importancia predictiva.

Luego se agruparon por categorías y se cuantificó la importancia acumulada por cada una, donde temporal y geográfico explican conjuntamente el 91.85% del poder predictivo.

Tabla 6

Importancia de Variables por Categorías

Categoría	Importancia acumulada
Temporal	53.08%
Geográfico	38.77%
Atención de salud	2.83%
Educación	1.52%
Edad de la madre	1.04%
Reproductivo	0.99%

Estado civil	0.40%
--------------	-------

Nota. Las categorías temporal (53.08%) y geográfico (38.77%) capturan la mayor varianza explicativa.

Las variables sociodemográficas tradicionales mostraron influencia limitada, sugiriendo que los patrones espacio-temporales agregados capturan mejor la dinámica demográfica que las características individuales.

Los resultados demuestran la efectividad del enfoque propuesto para la predicción de natalidad, con XGBoost mostrando la mayor eficiencia predictiva ($R^2=0.9107$, $MAE=0.1618$) y superando significativamente a los demás modelos evaluados. La optimización de hiperparámetros permitió balancear complejidad y generalización, resultando en un modelo robusto que captura efectivamente las relaciones no lineales en los datos demográficos sin presentar sobreajuste, validando así la aplicabilidad de los algoritmos de machine learning para este tipo de problemas de pronóstico espacio-temporal.

5. Conclusión

Este estudio validó exitosamente el uso de modelos de machine learning para predecir la tasa de natalidad trimestral a nivel departamental en el Perú, superando consistentemente las métricas establecidas en la hipótesis inicial. El modelo XGBoost demostró el mejor desempeño predictivo con R^2 de 0.9107 y MAE de 0.1618 en el conjunto de prueba, superando ampliamente los umbrales de $R^2 > 0.7$ y $MAE < 0.5$ planteados originalmente.

El análisis reveló que los patrones temporales (53.08%) y la heterogeneidad geográfica (38.77%) son los principales determinantes de la natalidad, representando en conjunto más del 90% del poder predictivo. Las variables de series de tiempo (lag1, lag4, ma4) capturan la inercia temporal y estacionalidad de la natalidad, mientras que las diferencias departamentales reflejan las disparidades regionales en los patrones demográficos. En contraste, las variables sociodemográficas tradicionales mostraron influencia limitada, sugiriendo que los patrones agregados espacio-temporales son más relevantes para la predicción que las características individuales.

La exclusión del período COVID-19 mejoró significativamente la robustez del modelo, confirmando que los eventos atípicos introducen ruido que afecta la capacidad de generalización. Esta decisión metodológica permitió desarrollar un predictor más estable y confiable para condiciones normales.

Estos hallazgos proporcionan una base sólida para la planificación descentralizada de políticas públicas en salud, educación y pensiones, permitiendo proyecciones confiables para la asignación de recursos y el diseño de intervenciones diferenciadas según patrones regionales específicos. La metodología implementada demuestra que los enfoques de machine learning pueden capturar complejas relaciones no lineales en datos demográficos, ofreciendo una alternativa robusta a los métodos tradicionales de proyección.

6. Sugerencias de trabajos futuros

- Incorporar indicadores de empleo, pobreza y migración para capturar determinantes estructurales de la natalidad.
- Desarrollar predictores específicos para costa, sierra y selva que consideren sus dinámicas demográficas particulares.
- Implementar modelos que detecten cambios abruptos en tendencias demográficas usando técnicas de detección de anomalías.
- Combinar XGBoost con modelos de series temporales profundas (LSTM, Transformer) para capturar dependencias temporales complejas.
- Desarrollar un dashboard en tiempo real para tomadores de decisiones con proyecciones y análisis de escenarios.

7. Implicancias éticas

- **Asignación de Recursos:** Predicciones inexactas podrían generar asignación insuficiente de recursos en salud (maternidades, pediatría) y educación (colegios, docentes), afectando servicios esenciales para la población.
- **Equidad Algorítmica:** El modelo podría perpetuar sesgos históricos, perjudicando a departamentos con menor representación en los datos y exacerbando desigualdades regionales existentes.
- **Privacidad de Datos:** Aunque se usan datos agregados, se requiere anonimización rigurosa y control de acceso para prevenir re-identificaciones o usos no autorizados de información sensible.
- **Transparencia:** La complejidad de los modelos de ML puede dificultar la comprensión por parte de tomadores de decisiones, reduciendo la accountability en políticas públicas.
- **Abordajes Propuestos:**
 - Establecer intervalos de confianza y comunicar incertidumbre en predicciones.
 - Implementar auditorías periódicas de sesgos por departamento.

- Desarrollar factores de ajuste para regiones con datos limitados.
- Utilizar herramientas de interpretabilidad (SHAP) para explicar predicciones.
- Garantizar cumplimiento de la Ley de Protección de Datos Personales del Perú.

8. Link del repositorio del trabajo

Repositorio en GitHub

https://github.com/LuisMirandaMallqui/Inteligencia_Artificial_TareaAcademica_Grupo8_H783.git

9. Declaración de contribución de cada integrante

- John Arzapalo: Cálculo de la población trimestral, realizado con fuentes de INEI anuales, además de apoyo en la documentación de los datasets.
- Ariana Burga: Búsqueda y selección de fuentes bibliográficas relevantes al tema, comparativa del mejor modelo con o sin periodo COVID-19, análisis de variables más influyentes y redacción del informe.
- Ricardo Lara: Preprocesamiento, exploración de rendimiento de modelos externos, elaboración de la presentación y el inciso de modelos del informe.
- Luis Miranda: Preprocesamiento, documentación de los datasets y notebooks empleados, así como del informe.
- Alessandro Santé: Responsable del preprocesamiento del dataset original hasta el cálculo de la variable target, así como adición de variables 'lag' al dataset. Investigación de TimeSeriesSplit para la separación de la data en dev y test.
- Juan Zavala: Responsable de la búsqueda y selección de fuentes bibliográficas relevantes al tema, elaboración de resúmenes críticos de dichas fuentes y ejecución del preprocesamiento completo de los datos utilizados en el estudio.

10. Referencias

- [1]. CASTELLARES, Renzo; Diego CAMACHO y Mario HUARANCCA
2024 "Reducción de la tasa de natalidad en el Perú: proyecciones y determinantes". *Moneda*. Lima, número 197, pp. 64-69. Consulta: 29 de setiembre de 2025.
<https://www.bcrp.gob.pe/docs/Publicaciones/Revista->

[Moneda/moneda-197/moneda-197-10.pdf](#)

- [2]. LARGO, Lida y Sebastián VALENCIA
2024 "Análisis de reducción de tasas de natalidad en Colombia: un enfoque con técnicas de aprendizaje automático". *Universidad de Antioquia*. Medellín. Consulta: 29 de setiembre de 2025.
<https://hdl.handle.net/10495/44526>
- [3]. ORDÓÑEZ-ERAZO, Hugo-Armando; Camilo ORDÓÑEZ y Víctor-Andrés BUCHELI-GUERRERO
2022 "Predicción de factores clave en el aumento de la demografía en Colombia a través del ensamble de modelos de Machine Learning". *Revista científica*. Bogotá, número 44, pp. 282-295. Consulta: 29 de setiembre de 2025.
<https://doi.org/10.14483/23448350.19205>
- [4]. THE ECONOMIST
2023 "Global fertility has collapsed, with profound economic consequences". *The Economist*. London, pp. s. p. Consulta: 29 de setiembre de 2025.
<https://www.economist.com/leaders/2023/06/01/global-fertility-has-collapsed-with-profound-economic-consequences>
- [5]. TZITIRIDOU-CHATZOPOULOU, Maria; Georgia ZOURNATZIDOU y Michael KOURAKOS
2024 "Predicting Future Birth Rates with the Use of an Adaptive Machine Learning Algorithm: A Forecasting Experiment for Scotland". *International Journal of Environmental Research and Public Health*. Basilea, volumen 21, número 7, pp. 1-11. Consulta: 29 de setiembre de 2025.
<https://doi.org/10.3390/ijerph21070841>