

Predicción trimestral de la tasa de natalidad en el Perú:

Una comparación de modelos de Machine Learning a nivel departamental

Grupo 08

- Ariana Burga
- Luis Miranda
- Juan Zavala
- Alessandro Santé
- Ricardo Lara
- John Arzapalo




Problemática:

A nivel global, la tasa de natalidad ha mostrado un declive consistente durante el último siglo, tendencia que se replica en el contexto peruano con particularidades regionales que demandan un análisis específico a **nivel departamental**.



- **Invierno demográfico**

La **reducción progresiva de la tasa de nacimiento** genera desafíos asociados al envejecimiento poblacional, donde una base reducida de población joven debe sustentar económicamente a un creciente número de adultos mayores.



- **Métodos tradicionales**

Los **métodos tradicionales de proyección demográfica** presentan limitaciones al no capturar la complejidad de las relaciones entre variables sociodemográficas a nivel subnacional.

Objetivos del proyecto:

Desarrollar un modelo predictivo de la tasa de natalidad trimestral utilizando modelos de machine learning.

01

Procesar y transformar los datos con técnicas de preprocesamiento, ingeniería de características y agregación trimestral departamental.

02

Implementar y entrenar los modelos considerando la naturaleza temporal de los datos.

03

Evaluar y comparar el desempeño predictivo utilizando métricas estandarizadas (MSE, MAE, R^2) con validación temporal.

04

Identificar y analizar las variables con mayor influencia predictiva en el modelo de mejor desempeño.

Trabajos anteriores:




**UNIVERSIDAD DISTRITAL
FRANCISCO JOSÉ DE CALDAS**
Acreditación Institucional de Alta Calidad




**UNIVERSIDAD
DE ANTIOQUIA**

Modelos más utilizados:


XGBoost




KNN




Regresión Lineal



Árbol de regresión



Random Forest





METODOLOGÍA

Nacidos vivos.csv

Cada registro es un nacimiento

FecNac_Año	Año de nacimiento (4 dígitos)
FecNac_Mes	Mes de nacimiento (2 dígitos)
PESO_NACIDO	Peso del recién nacido en gramos
TALLA_NACIDO	Talla del recién nacido en centímetros
DJ/L_EMB_PARTO	Duración del embarazo en semanas
Condicion_Part	Condición del parto (eutóxico, instrumentado, cesárea)
Sexo_nacido	Sexo del recién nacido (masculino/femenino)
Tipo_Part	Tipo de parto (único, doble, triple, etc.)
Edad_Madre	Edad de la madre en años
Estado_Civil	Estado civil de la madre
Nivel_Instrucción_Madre	Nivel educativo de la madre


Edad_Madre	Edad de la madre en años
Estado_Civil	Estado civil de la madre
Nivel_Instrucción_Madre	Nivel educativo de la madre
Num_embar_madre	Número de embarazos previos de la madre
Hijos_vivo_madre	Número de hijos vivos de la madre
Hijos_fallec_madre	Número de hijos fallecidos de la madre
nacmuer_abort_madre	Número de abortos de la madre
Pais_Madre	País de origen de la madre
IdUbigeolnei	Código de ubicación geográfica (INEI)
DESC_OCUPACION	Ocupación de la madre
lpress	Establecimiento de salud (RENIPRESS)
Lugar_Nacido	Lugar donde ocurrió el nacimiento
Atiende_Part	Personal que atendió el parto
Financiador_Part	Método de financiamiento del parto

Nota: Este dataset nos sirve como punto de partida pero faltan agrupaciones trimestrales y por departamento.


- Datos de la madre
- Datos del nacido
- Datos del nacimiento
- Datos para agrupar

Problema: Calculo de la población trimestral

Para calcular la tasa de natalidad trimestral se requiere tanto el número de nacimientos como la **población correspondiente en cada período**. Si bien contamos con los registros detallados de nacimientos a nivel departamental, **no disponemos de datos oficiales de población trimestral**.



Archivos utilizados:




Preprocesamiento

Limpieza

- Se eliminaron 953 registros duplicados
- Se trataron valores inválidos ("IGNORADO" → NaN)
- Se normalizaron valores numéricos especiales
- Se eliminó columna con 97% de valores nulos

Selección y Transformación de Características:

- Se eliminaron 10 variables no relevantes del bebé y parto
- Se agruparon categorías en estado civil, educación, lugar de nacimiento y financiador



Integración del target


Datos individuales del nacimiento transformados a un formato agregado

Integración Geográfica y Temporal:

- Se vincularon nacimientos con datos geográficos usando código Ubigeo
- Se creó variable trimestre a partir del mes de nacimiento
- Se eliminaron registros sin departamento asignado

Cálculo de Poblaciones Trimestrales:


- Se generaron estimaciones trimestrales poblacionales mediante interpolación lineal con tasas históricas por departamento.



Agregación Espacio-Temporal:

- Se agruparon datos por año, departamento y trimestre
- Se calcularon totales de nacimientos y estadísticas de edad materna
- Se obtuvieron promedios de variables reproductivas y proporciones de categorías agrupadas

Estructuración de Datos



Análisis de correlación


- Mediante la matriz de correlación se eliminaron las variables que sobrepasan el umbral de 0.90 de correlación

División Temporal de Datos:

- Se utilizó Time Series Cross Validation.
- Se excluyó período COVID (2020-2021-T2) para mayor robustez predictiva



Ingeniería de Características Temporales:

- Se crearon variables temporales: Lag1 (trimestre anterior), Lag4 (mismo trimestre año anterior) y MA4 (media móvil 4 trimestres)
- 



Time Series Cross Validation

- Es una técnica que respeta el **orden temporal de los datos**. Funciona mediante ventanas de entrenamiento expandibles donde cada fold incorpora más datos históricos para predecir períodos futuros consecutivos.
- Esta aproximación simula escenarios reales de predicción donde el modelo se entrena con datos históricos disponibles y se prueba su capacidad para predecir años futuros.



Dataset final

Departamento	División geográfica/regional del país
Año	Año del registro de natalidad
Trimestre	Período trimestral (1-4) del año
Edad_Media	Edad promedio de las madres al momento del parto
Pct_Adolescentes	Porcentaje de madres adolescentes (<20 años)
Pct_Mayores35	Porcentaje de madres mayores de 35 años
Embarazos_Prom	Número promedio de embarazos por mujer
HijosVivos_Prom	Número promedio de hijos vivos por mujer
Abortos_Prom	Número promedio de abortos por mujer
Pct_EstadoCivil_CON_PAREJA	Porcentaje de madres en unión conyugal
Pct_Nivel_PRIMARIA_BAJA	Porcentaje con educación primaria o menos
Pct_Nivel_SECUNDARIA	Porcentaje con educación secundaria completa
Pct_Nivel_SUPERIOR	Porcentaje con educación superior o universitaria

Pct_Lugar_INSTITUCIONAL	Porcentaje de partos en instituciones de salud
Pct_Financ_ESSALUD	Porcentaje financiado por el seguro social ESSALUD
Pct_Financ_PRIVADO	Porcentaje financiado por seguros privados
Pct_Financ_SANIDADES	Porcentaje financiado por sanidades de FFAA
Pct_Financ_SIS	Porcentaje financiado por el Seguro Integral de Salud
Poblacion_Trimestral	Población total del departamento en el trimestre
lag1	Valor de la tasa de natalidad del trimestre anterior
lag4	Valor de la tasa de natalidad del mismo trimestre del año anterior
ma4	Media móvil de 4 trimestres de la tasa de natalidad
Tasa_Natalidad_Trimestral	Variable objetivo - Tasa de natalidad por cada 1000 habitantes

Estrategia Experimental:

Se diseñaron cuatro experimentos principales:

Comparación base

Evaluación de los 5 algoritmos mediante validación cruzada temporal (TimeSeriesSplit) con configuración estándar.

Entrenamiento final

Entrenamiento de modelos con conjunto completo (train + validation) para evaluación en test.

Evaluación temporal

Prueba en datos recientes (2024 - 2025) para simular desempeño en producción.

Robustez COVID

Comparativa excluyendo el período atípico (2020 - 2021-T2) para validar generalización.



Modelos

Para este trabajo se desarrollaron cinco modelos predictivos, seleccionados para representar diferentes enfoques algorítmicos y evaluar su capacidad para capturar patrones espacio-temporales en datos demográficos:

Paradigmas de predicción

- Lineal
- Por similitud
- Basados en árboles

La comparación sistemática entre estos modelos permite evaluar distintos paradigmas de predicción y determinar cuál se ajusta mejor a la naturaleza espacio-temporal de los datos demográficos a nivel departamental.



Configuración de Modelos

Cada algoritmo se configuró con hiperparámetros específicos determinados mediante experimentación preliminar:

	KNN
Número de vecinos	5 y 10

Para evaluar sensibilidad al número de vecinos

	Árbol de Regresión
Profundidad	6

Para balancear complejidad y generalización.

	Random Forest
Profundidad	6
Número de estimadores	100

Para un ensemble robusto

	XGBoost
Profundidad	6
Learning rate	0.05
Número de estimadores	200

Optimizado para relaciones complejas

Esta configuración experimental permite caracterizar completamente el desempeño de cada enfoque y responder directamente a las preguntas de investigación sobre efectividad predictiva comparativa.

Métricas de Evaluación:

Se seleccionaron tres métricas estandarizadas para evaluación comparativa:

R²:

Mide la proporción de varianza explicada por el modelo en la escala 0-1.

$$R^2 = 1 - \frac{\sum (y_i - \hat{y})^2}{\sum (y_i - \bar{y})^2}$$

Where,

$\hat{y}$ – predicted value of y

$\bar{y}$ – mean value of y

RMSE:

Cuantifica el error cuadrático promedio en la escala original de la tasa de natalidad (puntos por 1000 habitantes).

$$RMSE = \sqrt{MSE} = \sqrt{\frac{1}{N} \sum_{i=1}^N (y_i - \hat{y})^2}$$


MAE:

Representa el error absoluto promedio, menos sensible a valores atípicos


$$MAE = \frac{1}{N} \sum_{i=1}^N |y_i - \hat{y}|$$

Regresión Lineal:


Se utilizó como modelo baseline por su simplicidad y transparencia interpretativa. Permite establecer relaciones lineales entre las variables predictoras y la tasa de natalidad, sirviendo como referencia para modelos más complejos.



R^2 : 0.7309



RMSE : 0.3527




MAE : 0.2737

K-Nearest Neighbors (KNN)


Este modelo estima la tasa esperada basándose en los trimestres y departamentos más similares históricamente, aprovechando la estructura de panel de los datos.

En este caso se implementó con $k=5$ y $k=10$ para capturar patrones de similitud temporal y espacial.


K=5



$R^2 : 0.7027$




RMSE : 0.3636




MAE : 0.2892

K-Nearest Neighbors (KNN)


K=10




R^2 : 0.6544



RMSE : 0.4075




MAE : 0.3280




Árbol de Regresión

Se configuró con máxima profundidad de 6 para identificar umbrales críticos y relaciones no lineales. Su capacidad de interpretación permite detectar cambios estructurales específicos por departamento y capturar interacciones entre variables temporales y geográficas.




R^2 : 0.7118



RMSE : 0.3606




MAE : 0.2715




Random Forest


Ensamble de 100 árboles con máxima profundidad 6, que combina múltiples árboles de decisión para reducir sobreajuste y mejorar la generalización para departamentos con menor cantidad de datos históricos.




$R^2 : 0.8493$



RMSE : 0.2747




MAE : 0.2107




XGBoost


Modelo de boosting gradient con 200 estimadores, learning rate de 0.05 y máxima profundidad de 6. Optimizado para capturar relaciones complejas mediante el aprendizaje secuencial de árboles, particularmente efectivo para las dependencias temporales (lags) y la heterogeneidad departamental.



R^2 : 0.8632



RMSE : 0.2593



MAE : 0.1955

Experimentación y resultados

Resultados y Discusión

Resultados de Validación Cruzada Temporal

Modelo	R2 promedio	RMSE promedio	MAE promedio
Regresión Lineal	0,7309	0,3527	0,2737
KNN (k=5)	0,7027	0,3636	0,2892
KNN (k=10)	0,6544	0,4075	0,3280
Árbol de Regresión	0,7118	0,3606	0,2715
Random Forest	0,8493	0,2747	0,2107
XGBoost	0,8632	0,2593	0,1955


Los resultados de la validación cruzada temporal revelaron que XGBoost obtuvo el mejor desempeño global seguido por Random Forest

La superioridad de estos modelos basados en arboles dan a entender que las relaciones no lineales y las interacciones entre variables son cruciales para predecir la natalidad.

Al ser el mejor modelo, XGBoost fue reentrenado con el conjunto completo de entrenamiento y validación (2015 - 2023) y evaluado en el período de prueba 2024 - 2025

XGBoost-Mejor modelo


Modelo modificado con los siguientes parámetros: 600 estimadores, learning rate de 0.05 y máxima profundidad de 8.



R2	MAE	RMSE
0.9107	0.2144	0.1618

- El modelo confirmó su capacidad de generalización. El R^2 supera el umbral de 0.7, y el MAE está por debajo de 0.5.
- La consistencia entre validación y prueba, con una mejora en el R^2 de 0.8632 a 0.9107, indica que el modelo no sufre de sobreajuste significativo y generaliza adecuadamente a datos futuros

Gráfico de líneas comparativo



Análisis de Importancia de Variables

Para interpretar los resultados y comprender los factores subyacentes a las predicciones, se implementó un análisis en el modelo XGBoost.


Temporal	Geográfico	Edad Materna	Sociodemográfico	Salud Reproductiva
Lag1	Dummy de departamento	Edad	Educación	Embarazos
Lag4		Media	Estado civil	Hijos vivos
Ma4		Porcentaje de adolescentes	Características de atención	Abortos
Año		Porcentaje mayor a 35 años		
Trimestre				

Las variables se clasificaron en categorías temáticas para un análisis interpretativo

Impacto del Período COVID-19 en XGBoost


Condición	R2	RMSE	MAE
Sin COVID	0,9107	0,2144	0,1618
Con COVID	0,8887	0,2394	0,1840

Los resultados evidencian que la exclusión del período COVID-19 mejoró todas las métricas. Este resultado respalda la decisión de excluir el período pandémico, ya que los eventos atípicos introducen ruido que dificulta la generalización del modelo y la identificación de patrones estructurales.



Variables con mayor relevancia:

Top 15 variables mas importantes en XGBoost



Importancia de Variables por Categorías

Categoría	Importancia acumulada
Temporal	53,08%
Geográfico	38,77%
Atención de salud	2,83%
Educación	1,52%
Edad de la madre	1,04%
Reproductivo	0,99%
Estado civil	0,04%

Conclusiones:

Se desarrolló exitosamente un sistema de machine learning para predecir la tasa de natalidad trimestral a nivel departamental en Perú. El modelo **XGBoost** demostró un rendimiento excepcional, superando consistentemente todas las métricas establecidas en la hipótesis inicial.

Principales determinantes de la natalidad

Las variables de series de tiempo (lag1, lag4, ma4) capturan la inercia temporal y estacionalidad de la natalidad

Variables limitadas: Sociodemográficas

Patrones agregados espacio-temporales son más relevantes para la predicción que las características individuales.


Sobre la exclusión del periodo COVID-19

- Mejora significativa en la robustez del modelo, confirmando que los eventos atípicos introducen ruido que afecta la capacidad de generalización.
- Esta decisión metodológica permitió desarrollar un predictor más estable y confiable para condiciones normales.

Sobre la metodología

Los enfoques de machine learning pueden capturar complejas relaciones no lineales en datos demográficos, ofreciendo una alternativa robusta a los métodos tradicionales de proyección.

Implicancias éticas



Asignación de Recursos:


Predicciones inexactas podrían generar asignación insuficiente de recursos en salud (maternidades, pediatría) y educación (colegios, docentes), afectando servicios esenciales para la población.

Equidad Algorítmica:

El modelo podría perpetuar sesgos históricos, perjudicando a departamentos con menor representación en los datos y exacerbando desigualdades regionales existentes.


Privacidad de Datos:

Aunque se usan datos agregados, se requiere anonimización rigurosa y control de acceso para prevenir re-identificaciones o usos no autorizados de información sensible.



Transparencia:

La complejidad de los modelos de ML puede dificultar la comprensión por parte de tomadores de decisiones, reduciendo la accountability en políticas públicas.



Sugerencias para trabajos futuros



01

Incorporar indicadores de empleo, pobreza y migración para capturar determinantes estructurales de la natalidad.

02

Desarrollar predictores específicos para costa, sierra y selva que consideren sus dinámicas demográficas particulares.

03

Implementar modelos que detecten cambios abruptos en tendencias demográficas usando técnicas de detección de anomalías.

04

Combinar XGBoost con modelos de series temporales profundas (LSTM, Transformer) para capturar dependencias temporales complejas.

¡Muchas gracias!

